

Mini-projet 1 — Reuters-21578 (Actualités économiques)

Description

- Ensemble de **21 578 dépêches économiques** issues de l'agence Reuters, catégorisées par thèmes (*acq*, *earn*, *grain*, *money-fx*, etc.).
- Corpus classique pour l'apprentissage et la recherche d'information.

Accès

- Déjà inclus dans `nltk`:

```
import nltk
from nltk.corpus import reuters
nltk.download('reuters')
```

- Fichiers stockés localement après téléchargement (`nltk_data/corpora/reuters/`).

Format

- Chaque fichier = une dépêche (`.sgm`)
- Métadonnées : `reuters.fileids()`, `reuters.categories(fileid)`

Source

- [NLTK Reuters-21578 documentation](#)
- Licence : usage éducatif libre (provenance Reuters, 1987)

Mini-projet 2 — arXiv Physics (Articles scientifiques)

Description

- Métadonnées et résumés d'articles scientifiques arXiv (titre, résumé, catégorie, date).
- Sous-ensemble : *physics*, *cs*, *math*, *astro-ph*.

Accès

Télécharger l'échantillon libre :

-  [Kaggle – arXiv Metadata Dataset \(Cornell\)](#)
Fichier : `arxiv-metadata-oai-snapshot.json` (~7 GB, format JSON)

Créer un échantillon :

```
import pandas as pd, json
rows = []
with open('arxiv-metadata-oai-snapshot.json') as f:
    for i, line in enumerate(f):
        if i > 10000: break
        d = json.loads(line)
        rows.append((d['title'], d['abstract'], d['categories']))
df = pd.DataFrame(rows, columns=['title', 'abstract', 'categories'])
```

Licence


- CC BY 4.0 (Cornell University, arXiv.org)

Mini-projet 3 — Wikinews EN (Actualités internationales)

Description

- Articles anglophones issus de **Wikinews**, média libre collaboratif de la Wikimedia Foundation.
- Données ouvertes et multithématiques (politique, environnement, sport, etc.).

Accès

-  [Wikimedia Dumps](#)
→ télécharger le fichier `enwikinews-latest-pages-articles.xml.bz2`
- Extraction simplifiée possible avec `wikiextractor` :

```
pip install wikiextractor
python -m wikiextractor.WikiExtractor enwikinews-latest-pages-articles.xml.bz2 -o output/
```

ou un jeu nettoyé :

 [Kaggle – English Wikinews Dataset \(CSV\)](#)

Licence


- CC-BY-SA 3.0 (Wikimedia Foundation)

Mini-projet 4 — PubMed Open Access Subset (Corpus biomédical)

Description

- Résumés et métadonnées d’articles biomédicaux accessibles en open access (NLM / NIH).
- Champs : title, abstract, mesh_terms, journal, etc.

Accès

-  NCBI PubMed Central Open Access Subset (archives XML compressées)

Échantillon CSV libre :

-  Kaggle – PubMed Open Access Subset

Conseil

Extraire 10 000 abstracts max.

```
import pandas as pd
df = pd.read_csv("pubmed_200k_train.csv").sample(10000)
```

Licence


- CC-BY (National Library of Medicine, NIH)

Mini-projet 5 — Wikipedia FR (Articles culturels)

Description

- Articles francophones issus de la catégorie “Arts et Culture” (musique, peinture, littérature...).
- Contenu sous licence libre Wikimedia.

Accès

-  [Wikipedia FR Dumps](#)
→ fichier frwiki-latest-pages-articles.xml.bz2
Extraction :

```
python -m wikiextractor.WikiExtractor frwiki-latest-pages-articles.xml.bz2 -o output/
```

- **Alternative :**
 Kaggle – French Wikipedia Articles Dataset (CSV)

Licence


- CC-BY-SA 3.0 (Wikimedia Foundation)
-

Mini-projet 6 — Stack Exchange Data Science (Forum technique)


Description

- Données textuelles issues du forum **Data Science Stack Exchange** (questions, réponses, tags).
- Thèmes : apprentissage automatique, statistique, IA, Python, etc.

Accès

-  Archive Stack Exchange officielle
→ fichier : `datascience.stackexchange.com.7z`
- Extraction des champs Title, Body, Tags avec BeautifulSoup.

Ou jeu simplifié :

-  Kaggle – Data Science Stack Exchange Posts

Licence

- CC-BY-SA 4.0 (Stack Exchange Inc.)
-